

DetECCIÓN Avanzada de Anomalías

Análisis Exhaustivo, Características, Funcionamiento y Casos de Uso Industriales de LOF y One-Class SVM

DOCUMENTO TÉCNICO DE REFERENCIA DE ALTA DENSIDAD

1. Introducción y Paradigma de la Detección de Anomalías

En el ecosistema analítico moderno, la **detección de anomalías** representa uno de los desafíos más complejos e importantes del aprendizaje automático. Una anomalía, o valor atípico (*outlier*), no es simplemente un dato extremo; es una observación que genera sospechas al haber sido producida por un mecanismo o comportamiento fundamentalmente diferente al del resto de los datos generados de forma regular.

La relevancia estratégica de esta disciplina radica en su asimetría inherente: los eventos normales suelen ser masivos y de bajo valor crítico por unidad, mientras que los eventos anómalos son sumamente escasos, pero albergan un impacto catastrófico o un valor financiero y operativo incalculable. Identificar estas desviaciones a tiempo permite pasar de políticas reactivas y costosas a estrategias operativas proactivas capaces de mitigar amenazas en milisegundos.

2. Local Outlier Factor (LOF)

Introducido formalmente por Breunig, Kriegel, Ng y Sander en el año 2000, el algoritmo **LOF** revolucionó el campo de la minería de datos al romper con la métrica tradicional de la distancia global. Los algoritmos previos asumían implícitamente que los datos normales se agrupaban en una única región homogénea, catalogando como anomalía a todo aquello situado a una distancia euclidiana fija del centroide de la masa global.

LOF incorporó el concepto de **anomalía local**, partiendo de la premisa de que un conjunto de datos real posee topologías complejas con regiones de densidades muy variables. Un dato puede ser completamente normal si se sitúa en una zona dispersa, mientras que ese mismo dato, transportado a las inmediaciones de un clúster extremadamente denso, constituye una anomalía local evidente debido a la ruptura abrupta de la cohesión del vecindario.

Características Importantes

- **Sensibilidad al Contexto Densocéntrico:** Evalúa los puntos basándose en la densidad relativa de su entorno local inmediato, no del dataset completo.
- **Independencia de Distribuciones Teóricas:** Es un método no paramétrico; no asume que los datos sigan una distribución normal, uniforme o geométrica regular.

- **Métrica Continuo-Proporcional:** No proporciona una respuesta binaria rígida, sino un score continuo que mide de manera cuantitativa el grado de aislamiento del punto.

Funcionamiento y Algoritmo Matemático

El cálculo del score LOF para cualquier instancia u objeto se ejecuta a través de cuatro etapas estructuradas:

A. Distancia-k (*k-distance*): Para un parámetro entero *k* seleccionado, la *k-distance* de un punto *p* es la distancia euclidiana $d(p, o)$ hacia su vecino más cercano número *k*. El vecindario local del punto se denota como $N_k(p)$ y contiene todos los elementos dentro de este radio.

B. Distancia de Alcanzabilidad (*Reachability Distance*): Para evitar inestabilidades matemáticas causadas por el ruido en áreas altamente densas, la distancia de alcanzabilidad del punto *p* con respecto a un vecino *o* se define como el valor máximo entre la propia densidad del vecino y la distancia real:

$$reach-dist_k(p, o) = \max(\{ k-distance(o), d(p, o) \})$$

C. Densidad de Alcanzabilidad Local (LRD): La *LRD* representa la densidad estimada del vecindario de *p*. Se calcula como el inverso del promedio de las distancias de alcanzabilidad de sus vecinos:

$$LRD_k(p) = |N_k(p)| / \sum_{o \in N_k(p)} reach-dist_k(p, o)$$

D. Factor LOF Final: Es el promedio ponderado del cociente entre la *LRD* de los vecinos del punto y la propia *LRD* del punto en evaluación:

$$LOF_k(p) = (\sum_{o \in N_k(p)} [LRD_k(o) / LRD_k(p)]) / |N_k(p)|$$

Si el score es cercano a 1, la densidad del punto es similar a la de su entorno (comportamiento normal). Si el score es muy superior a 1, significa que su densidad local es muy baja, lo que indica que se encuentra aislado y es, por tanto, una anomalía local.

Caso de Uso Real en la Industria para LOF: Telecomunicaciones y Consumo de Datos Móviles

Contexto industrial: Las empresas globales de telecomunicaciones gestionan perfiles de millones de usuarios simultáneamente. En su base de datos conviven de forma legítima perfiles radicalmente opuestos: usuarios corporativos avanzados que consumen cientos de gigabytes de datos en horarios laborales fijos, y usuarios de perfiles básicos o adultos mayores que consumen menos de 1 GB mensual en aplicaciones de mensajería básica.

Aplicación de LOF: Si una cuenta asociada a un plan básico sufre una brecha de seguridad (por ejemplo, el dispositivo es infectado y transformado en un nodo de una *botnet* de spam o minería de criptomonedas), su consumo se disparará a 15 GB mensuales en horarios nocturnos. Si la empresa usara un algoritmo de detección global, este consumo jamás se activaría como alerta porque 15 GB está muy por debajo de los patrones de los clientes corporativos.

Al implementar LOF (configurando un vecindario k adaptado a perfiles similares), el algoritmo detecta de inmediato que el comportamiento se sale por completo de la densidad de su micro-clúster. El score de este cliente escala a un valor de $LOF = 4.2$, activando una alerta temprana automatizada que suspende temporalmente el tráfico fraudulento de datos antes de saturar las antenas locales o generar cobros excesivos al cliente.

3. One-Class SVM (Support Vector Machine)

El modelo **One-Class SVM**, desarrollado por Schölkopf y su equipo de investigación, cambia el enfoque de densidad por un enfoque puramente geométrico y de frontera. Es un algoritmo diseñado específicamente para resolver problemas con un desequilibrio extremo de clases o donde se carece por completo de muestras de la clase anómala durante la fase de entrenamiento del modelo.

A diferencia de las SVM de clasificación tradicionales que buscan el mejor hiperplano para separar dos grupos de datos perfectamente etiquetados, One-Class SVM asume un reto de clase única. Su objetivo es aprender el contorno y la estructura tridimensional que encierra al comportamiento normal y trazar una frontera hermética a su alrededor en un espacio transformado. Cualquier observación futura que caiga del lado exterior de dicha frontera geográfica es rechazada y catalogada como un elemento anómalo.

Características Importantes

- **Modelado Semi-Supervisado Eficiente:** Se entrena única y exclusivamente con instancias que representan el funcionamiento óptimo del sistema, abstrayendo sus reglas intrínsecas.

- **Truco del Kernel Avanzado:** Utiliza funciones de mapeo matemático no lineales (generalmente el Kernel de Función de Base Radial, RBF) para proyectar los datos de entrada a un espacio abstracto hiperdimensional.
- **Modelo de Inferencia Inductivo:** Genera una función matemática fija de decisión. Esto permite evaluar nuevos registros individuales en tiempo real con un costo computacional despreciable, haciéndolo ideal para implementaciones en producción de baja latencia.

Funcionamiento y Formulación Matemática

En el espacio original, los límites de la clase normal pueden estar entrelazados y ser imposibles de delimitar mediante una línea recta o plano continuo. Al mapear las instancias mediante el truco del kernel al espacio de características hiperdimensional, One-Class SVM trata estratégicamente al ****origen de coordenadas**** $(0, 0, \dots, 0)$ como la única representación disponible del "universo anómalo".

El algoritmo optimiza la ubicación de un hiperplano para maximizar la separación entre el origen y toda la masa de datos limpios de entrenamiento, resolviendo la siguiente función objetivo sujeta a penalizaciones:

$$\min_{w, \xi, b} (1/2 \|w\|^2 + 1/(v n) \sum_{i=1}^n \xi_i - b)$$

Sujeto a la restricción geométrica de que para todo vector de entrenamiento, la proyección matemática cumpla:

$$(w \cdot \Phi(x_i)) \geq b - \xi_i \quad \xi_i \geq 0$$

Donde w representa el vector normal al hiperplano, b es el sesgo del desplazamiento del margen, ξ_i son variables de holgura que toleran pequeñas violaciones a la frontera, y v (Nu) es el parámetro fundamental de calibración. v controla de forma simultánea la proporción máxima de falsos positivos aceptados durante el entrenamiento y establece la proporción mínima de vectores de soporte que definirán físicamente la rigidez o flexibilidad de la frontera final.

Caso de Uso Real en la Industria para One-Class SVM: Mantenimiento Predictivo en Energía Eólica

Contexto industrial: Los parques de generación de energía eólica en alta mar instalan aerogeneradores de millones de dólares. Debido a que son máquinas de ingeniería avanzada recientemente desarrolladas, estas turbinas operan durante sus primeros meses sin registrar absolutamente ningún fallo estructural o mecánico masivo. La empresa de energía no puede usar modelos de clasificación binaria tradicionales porque carece por completo de datos para entrenar la clase "Turbina rota".

Aplicación de One-Class SVM: Durante los primeros tres meses de puesta en marcha, se recopilan de forma continua lecturas de telemetría provenientes de cientos de sensores integrados: vibración milimétrica de las aspas, temperatura interna del eje de transmisión, velocidad de rotación del generador y voltaje de salida. Con estos datos limpios de "comportamiento sano", se entrena un modelo One-Class SVM utilizando un Kernel RBF. El algoritmo aprende la compleja firma geométrica de operación de la turbina.

En el quinto mes de operación, un engranaje interno sufre una microfisura imperceptible. De forma individual, la temperatura se mantiene en rangos tolerables y la vibración apenas aumenta una fracción decimal; ningún sensor por separado activa una alarma convencional. Sin embargo, la combinación conjunta de estas variables genera un vector multidimensional que se posiciona fuera de la frontera espacial aprendida por el algoritmo. One-Class SVM evalúa el punto en milisegundos, detecta que cruzó al lado exterior del hiperplano de soporte y dispara una alerta preventiva inmediata. La empresa detiene la turbina de forma controlada y reemplaza un rodamiento por una fracción del costo, evitando un fallo catastrófico y ahorrando millones en reparaciones de emergencia en alta mar.

4. Arquitectura Comparativa de Modelos

La selección del algoritmo idóneo para un proyecto de minería de datos requiere un entendimiento profundo de los límites arquitectónicos de cada modelo. La siguiente matriz técnica sintetiza las diferencias fundamentales entre los enfoques basados en densidades locales (LOF) y los basados en fronteras hiperdimensionales (One-Class SVM):

Dimensión Técnica	Local Outlier Factor (LOF)	One-Class SVM (OC-SVM)
Estrategia Algorítmica	Medición de ratios de densidad local comparada contra los vecindarios más cercanos.	Optimización de un hiperplano de separación maximal respecto al origen de coordenadas.
Hiperparámetro Crítico	k (Número de vecinos para construir el entorno de densidad).	ν (Nu - Proporción máxima de outliers tolerados en el límite).
Naturaleza Operativa	No inductivo (*Lazy learner*). El modelo tradicional requiere los datos históricos para calcular scores.	Inductivo. Produce una función matemática frontera fija tras la fase de optimización.
Rendimiento en Tiempo Real	Complejo y demandante. Requiere algoritmos de aproximación indexada para streaming.	Excelente y óptimo. La inferencia se reduce a una evaluación matricial directa de vectores de soporte.
Comportamiento con Alta Dimensionalidad	Deficiente. Sufre la degradación de distancias euclidianas cuando el número de variables crece.	Excelente. El uso del truco del kernel está diseñado específicamente para manejar espacios de dimensiones infinitas.
Requisito de Datos	Tolera un dataset mixto o contaminado de manera inicial para estimar variaciones locales.	Requiere estrictamente un conjunto de entrenamiento limpio, representativo del estado óptimo normal.
Explicabilidad Teórica	Moderada a alta. Es posible rastrear matemáticamente el vecindario para explicar la caída de densidad.	Baja (Caja Negra). La transformación no lineal del espacio RBF impide mapear el peso directo de cada variable original.